

5.1 ¿Qué es el Aprendizaje Automático?

Un programa informático **aprende** de la **experiencia E** en relación a una **tarea T**, utilizando una **medida de rendimiento P**, si mejora sus prestaciones, medidas mediante **P**, en la realización de la tarea **T** a través de la experiencia **E**.

Esto suena complicado, pero es simple. Vamos a desglosarlo:

Ejemplo: Programa que juega a las damas

Componente	Significado	En el ejemplo de damas
T (Tarea)	Lo que queremos que haga el programa	Jugar a las damas
E (Experiencia)	Los datos o situaciones con las que aprende	Jugar muchas partidas
P (Performance/Rendimiento)	Cómo medimos si lo hace bien	Probabilidad de ganar la próxima partida

En resumen: El programa **aprende a jugar mejor a las damas** (T) jugando muchas partidas (E), y sabemos que aprende porque cada vez gana más veces (P).

5.2 ¿Por qué es importante el Aprendizaje Automático?

1. **Hacer viables ciertas aplicaciones** que serían imposibles de programar manualmente
 - Ejemplo: Reconocimiento facial con millones de variaciones
2. **Construir una IA de propósito general**
 - En lugar de programar reglas específicas, el sistema aprende de forma general
3. **Avances tecnológicos actuales:**
 - Mayor potencia de cálculo
 - Mayor capacidad de almacenamiento
 - Disponibilidad masiva de datos
 - Mejores algoritmos

5.3 Estrategias de Aprendizaje

Imagina que estás enseñando a un niño a identificar frutas:

5.3.1 Aprendizaje Supervisado

Definición: Durante el entrenamiento, le dices al sistema **exactamente qué respuesta es correcta** para cada ejemplo.

Analogía: Como un profesor que corrige un examen mostrando la respuesta correcta.

Ejemplo:

Entrada: [Imagen de manzana] → Etiqueta: "Manzana"

Entrada: [Imagen de naranja] → Etiqueta: "Naranja"

Entrada: [Imagen de plátano] → Etiqueta: "Plátano"

El sistema aprende: "Cuando vea esta forma y color → es una manzana"

5.3.2 Aprendizaje No Supervisado

Definición: Le das datos al sistema **SIN etiquetas**, y él debe encontrar patrones por sí mismo.

Analogía: Como darle a un niño una caja de botones y pedirle que los agrupe como quiera.

Ejemplo:

Le das: [, , , , , ,]

El sistema agrupa:

Grupo 1 (rojos, redondos):

Grupo 2 (naranjas, redondos):

Grupo 3 (amarillos, alargados):

Aplicaciones reales: - Segmentación de clientes (agrupar clientes similares) - Detección de anomalías - Compresión de datos

5.3.3 Aprendizaje por Refuerzo

Definición: El sistema recibe **señales de recompensa o castigo** según sus acciones, pero no se le dice explícitamente qué hacer.

Analogía: Como entrenar a un perro con premios cuando hace algo bien.

Ejemplo: Robot aprendiendo a caminar

Acción: Da un paso hacia adelante

Resultado: No se cae

Señal: +10 puntos (recompensa)

Acción: Se inclina demasiado

Resultado: Se cae

Señal: -50 puntos (castigo)

Aplicaciones reales: - Videojuegos (AlphaGo) - Robots industriales - Vehículos autónomos

5.4 Tipos de Problemas en Aprendizaje Supervisado


5.4 Problemas de Regresión

Objetivo: Predecir un **valor numérico continuo**.

Definición simple: Encontrar la función (curva/línea) que mejor se ajuste a los datos.

Ejemplo visual:

Precio de casas según tamaño



Lo que aprende el algoritmo: La línea que mejor predice el precio según el tamaño.

Pregunta típica: “¿Cuánto costará una casa de 120m²?” → Respuesta: ~250,000€

Otros ejemplos: - Predecir temperatura mañana - Estimar ventas del próximo mes - Predecir edad de una persona por su foto

5.4.2 Problemas de Clasificación


Objetivo: Asignar datos a **categorías discretas** (clases).

Definición simple: Encontrar la frontera que separa diferentes grupos.

Ejemplo visual:

Clasificar tumores: benigno vs maligno

Tamaño



Pregunta típica: “¿Este tumor es benigno o maligno?” → Respuesta: Clase (benigno/maligno)

Otros ejemplos: - Email: spam/no spam - Imagen: gato/perro/pájaro - Transacción: fraude/legítima

5.4.3 Importancia de las Características

Aumentar el número de características **relevantes** mejora el aprendizaje.

Ejemplo de clasificación de tumores:

Con 1 característica (solo tamaño):

Difícil separar benignos de malignos

Con 2 características (tamaño + edad):

Mejor separación

Con 3 características (tamaño + edad + densidad):

Separación aún mejor

5.5 Regresión Lineal

La regresión lineal es el algoritmo más básico de aprendizaje supervisado.

5.5.1 Componentes del Sistema

Notación estándar:

Símbolo	Significado
m	Número de ejemplos de entrenamiento
n	Número de características (features)
x	Variables de entrada / características
y	Variable de salida / respuesta
(x, y)	Un par entrada-salida genérico
(x⁽ⁱ⁾, y⁽ⁱ⁾)	El i-ésimo par entrada-salida
x⁽ⁱ⁾_j	Valor de la característica j en el ejemplo i

5.5.2 Modelo de Aprendizaje

Flujo del proceso:

1. Conjunto de Entrenamiento
↓
2. Algoritmo de Aprendizaje
↓
3. Hipótesis h (función aprendida)

↓

4. Para nueva entrada $x \rightarrow h$ predice y

5.3 La Hipótesis h

Forma de la hipótesis (regresión lineal simple):

$$y = h_{\theta}(x) = \theta_0 + \theta_1 \cdot x$$

Componentes: - θ_0 (theta cero): Intercepto (valor cuando $x=0$) - θ_1 (theta uno): Pendiente (inclinación de la recta)

Ejemplo numérico:

$$h_{\theta}(x) = 50,000 + 2,000 \cdot x$$

Interpretación:

- Casa de 0 m²: 50,000€ (base)
- Por cada m² adicional: +2,000€
- Casa de 100 m²: $50,000 + 2,000 \times 100 = 250,000$ €

5.5.4 Función de Coste $J(\theta)$

Objetivo: Medir qué tan bien se ajusta nuestra línea a los datos.

Concepto: Queremos que nuestra predicción $h_{\theta}(x)$ esté lo más cerca posible del valor real y .

Error Cuadrático Medio (MSE):

$$J(\theta_0, \theta_1) = \frac{1}{2m} \times \sum (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Desglosando la fórmula: 1. $h_{\theta}(x^{(i)})$: Predicción para el ejemplo i 2. $y^{(i)}$: Valor real del ejemplo i 3. $(h_{\theta}(x^{(i)}) - y^{(i)})$: Error en el ejemplo i 4. $(\dots)^2$: Elevamos al cuadrado (penaliza errores grandes) 5. \sum : Sumamos errores de todos los ejemplos 6. $\frac{1}{2m}$: Promediamos (el $\frac{1}{2}$ simplifica derivadas)

Ejemplo numérico:

Datos reales:

$x = [50, 100, 150]$

$y = [150k, 250k, 350k]$

Nuestra línea: $h_{\theta}(x) = 50k + 2k \cdot x$

Predicciones:

$h_{\theta}(50) = 150k \rightarrow \text{Error} = (150k - 150k)^2 = 0$

$h_{\theta}(100) = 250k \rightarrow \text{Error} = (250k - 250k)^2 = 0$

$$h_{-}(150) = 350k \rightarrow \text{Error} = (350k - 350k)^2 = 0$$

$J() = 0$;Ajuste perfecto!

5.5.5 Descenso de Gradiente

Objetivo: Encontrar los valores de θ que **minimizan $J(\theta)$** . **Concepto visual:** Imagina que estás en una montaña y quieres bajar al valle (mínimo).





Figure 1: Pasted image 20251103114208.png

Algoritmo (repetir hasta convergencia):

$$\theta_j := \theta_j - \alpha \times \frac{\partial J}{\partial \theta_j}$$

Donde: - α (alpha): Tasa de aprendizaje (tamaño del paso) - $\frac{\partial J}{\partial \theta_j}$: Derivada parcial (dirección del descenso)

Forma específica para regresión lineal:

$$\theta_0 := \theta_0 - \alpha \times \frac{\partial}{\partial \theta_0} \times J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \times \frac{\partial}{\partial \theta_1} \times J(\theta_0, \theta_1)$$

$$\frac{\partial}{\partial \theta_j} \times J(\theta_0, \theta_1) = J(\theta_0, \theta_1) = \frac{\partial}{\partial \theta_j} \times \frac{1}{2m} \times \sum (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{\partial}{\partial \theta_j} \times \frac{1}{2m} \times \sum (\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2$$

$$j = 0 : \frac{\partial}{\partial \theta_0} \times J(\theta_0, \theta_1) = \frac{1}{m} \times \sum (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$j = 1 : \frac{\partial}{\partial \theta_1} \times J(\theta_0, \theta_1) = \frac{1}{m} \times \sum (h_{\theta}(x^{(i)}) - y^{(i)}) \times x^{(i)}$$

5.5.6 Ejemplo Paso a Paso

Problema: Predecir precio de casas según tamaño.

Datos de entrenamiento (m=3):

x (m ²)	y (precio €)
50	150,000
100	250,000
150	350,000

Paso 1: Inicializar parámetros

$\theta_0 = 0$

$\theta_1 = 0$

$\alpha = 0.01$ (tasa de aprendizaje)

Paso 2: Primera predicción

$h_{\theta}(x) = 0 + 0 \cdot x = 0$ (para todos los x)

Paso 3: Calcular coste inicial

$$\begin{aligned} J() &= (1/6) \times [(0-150k)^2 + (0-250k)^2 + (0-350k)^2] \\ &= (1/6) \times [22,500M + 62,500M + 122,500M] \\ &= 34,583M \leftarrow \text{¡Muy alto!} \end{aligned}$$

Paso 4: Calcular gradientes y actualizar θ

$$\begin{aligned} J/ &= (1/3) \times [(0-150k) + (0-250k) + (0-350k)] \\ &= -250,000 \end{aligned}$$

$$J/ = (1/3) \times [(0-150k) \times 50 + (0-250k) \times 100 + (0-350k) \times 150]$$

$$= -30,000,000$$

$$:= 0 - 0.01 \times (-250,000) = 2,500$$

$$:= 0 - 0.01 \times (-30,000,000) = 300,000$$

Paso 5: Nueva predicción

$$h_-(x) = 2,500 + 300,000 \cdot x$$

Repetir pasos 3-4 hasta que $J(\theta)$ deje de disminuir significativamente.

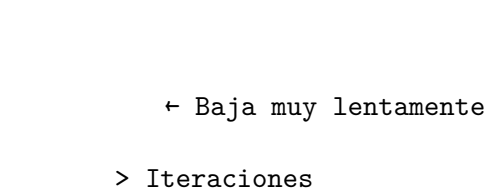
5.5.7 Tasa de Aprendizaje α

Concepto: Controla el tamaño de los pasos al descender.


Valor de α	Efecto	Problema
Muy pequeño (0.001)	Pasos muy pequeños	Convergencia MUY lenta □
Adecuado (0.01-0.1)	Pasos balanceados	Convergencia óptima □
Muy grande (10)	Pasos muy grandes	Puede no converger (oscila) □

Visualización del efecto de α :


muy pequeño:
J()



muy grande:
J()



adecuado:
J()



5.6 Regresión Lineal Multivariable

Hasta ahora: 1 característica (tamaño de casa) Ahora: Múltiples características (tamaño, habitaciones, edad, etc.)

5.6.1 Notación Extendida

Nueva forma de h:

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

En forma vectorial:

$$h_{\theta}(x) = \theta^T x$$

Donde:

$$\theta = [\theta_0, \theta_1, \theta_2, \dots, \theta_n]$$
$$x = [1, x_1, x_2, \dots, x_n] \quad (x_0 = 1 \text{ por convención})$$

5.6.2 Ejemplo con 3 características

Predicción de precio de casa:

Características:

x_1 = Tamaño (m^2)

x_2 = Número de habitaciones

x_3 = Edad (años)

$$h_{\theta}(x) = \theta_0 + \theta_1 \cdot \text{tamaño} + \theta_2 \cdot \text{habitaciones} + \theta_3 \cdot \text{edad}$$

Ejemplo con valores aprendidos:

$$h_{\theta}(x) = 80,000 + 2,000 \cdot \text{tamaño} + 10,000 \cdot \text{habitaciones} - 1,000 \cdot \text{edad}$$

Para una casa de $100m^2$, 3 habitaciones, 5 años:

$$\begin{aligned} h_{\theta}(x) &= 80,000 + 2,000 \times 100 + 10,000 \times 3 - 1,000 \times 5 \\ &= 80,000 + 200,000 + 30,000 - 5,000 \\ &= 305,000\text{€} \end{aligned}$$

6.3 Normalización de Características

Si las características tienen rangos muy diferentes, el descenso de gradiente converge lentamente.

Ejemplo:

x_1 = Tamaño: rango [50 - 200]

x_2 = Habitaciones: rango [1 - 5]

Solución: Feature Scaling

$$x_j^{(i)} := (x_j^{(i)} - \mu_j) / s_j$$

Donde:

= media de la característica j

s = desviación estándar de la característica j

Ejemplo numérico:

Original x (tamaño): [50, 100, 150, 200]

= (50+100+150+200)/4 = 125

s = desviación = 55.9

Normalizado:

x = [50-125]/55.9 = -1.34

x = [100-125]/55.9 = -0.45

x = [150-125]/55.9 = 0.45

x = [200-125]/55.9 = 1.34

Ahora todos están aproximadamente en el rango [-2, 2]

5.6.4 Ecuación Normal (Método Analítico)

Alternativa al descenso de gradiente: Calcular θ directamente con álgebra lineal.

Fórmula:

$$\theta = (X^T X)^{-1} X^T y$$

Donde:

X = matriz de características (m × n+1)

y = vector de salidas (m × 1)

Comparación con Descenso de Gradiente:

Descenso de Gradiente	Ecuación Normal
Necesita elegir α	No necesita α □
Necesita muchas iteraciones	Sin iteraciones □
Funciona bien con n grande (millones) □	Lento con n > 10,000 □
Necesita normalizar features	No necesita normalizar □
Complejidad $O(kn^2)$	Complejidad $O(n^3)$

5.7 Regresión Logística

Objetivo: Resolver problemas de **clasificación** (no regresión, a pesar del nombre).

5.7.1 ¿Por qué no usar regresión lineal para clasificación?

Problema visual:

Clasificar tumor: 0 (benigno) o 1 (maligno)

y
1 ← Malignos
 ← Benignos
0
 > Tamaño

Si usamos regresión lineal:

1

0
 >

Problemas:

- $h(x)$ puede ser > 1 o < 0
- Un tumor MUY grande altera toda la línea

5.7.2 Función Sigmoide (Logística)


Solución: Usar una función que siempre devuelva valores entre 0 y 1.

Fórmula:

$$g(z) = 1 / (1 + e^{-z})$$

$$h_{\text{lineal}}(x) = g(x) = 1 / (1 + e^{-(x)})$$

Gráfica:



$z \gg 0 \rightarrow g(z) \rightarrow 1$
 $z = 0 \rightarrow g(z) = 0.5$
 $z \ll 0 \rightarrow g(z) \rightarrow 0$

Interpretación:

$$h_{\text{lineal}}(x) = 0.7$$

Significa: "Hay un 70% de probabilidad de que $y=1$ "

5.7.3 Frontera de Decisión

Regla de decisión:

Si $h_-(x) \geq 0.5 \rightarrow \text{predecir } y=1$

Si $h_-(x) < 0.5 \rightarrow \text{predecir } y=0$

Como $g(z) = 0.5$ cuando $z = 0$:

Si $x \geq 0 \rightarrow \text{predecir } y=1$

Si $x < 0 \rightarrow \text{predecir } y=0$

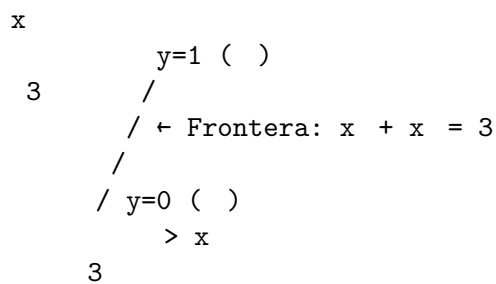
Ejemplo 1: Frontera lineal

$$h_-(x) = g(-3 + x + x^2)$$

Predecir $y=1$ cuando: $-3 + x + x^2 \geq 0$

Es decir: $x + x^2 \geq 3$

Gráfica:




Ejemplo 2: Frontera circular

$$h_-(x) = g(-1 + x^2 + x^2)$$

Predecir $y=1$ cuando: $x^2 + x^2 \geq 1$

Gráfica:



Interior (): $y=0$

Exterior (): $y=1$

5.7.4 Función de Coste para Regresión Logística

Problema: El error cuadrático hace que $J(\theta)$ sea no convexa (múltiples mínimos).

Solución: Nueva función de coste:

$$\begin{aligned}\text{Cost}(h_-(x), y) &= -\log(h_-(x)) && \text{si } y=1 \\ \text{Cost}(h_-(x), y) &= -\log(1 - h_-(x)) && \text{si } y=0\end{aligned}$$

Forma compacta:

$$\text{Cost}(h_-(x), y) = -y \cdot \log(h_-(x)) - (1-y) \cdot \log(1-h_-(x))$$

Función de coste total:

$$J() = -(1/m) \sum [y \cdot \log(h_-(x)) + (1-y) \cdot \log(1-h_-(x))]$$

Intuición:

Si $y=1$:

- $h_-(x) = 1 \rightarrow \text{Cost} = -\log(1) = 0$ Sin penalización
- $h_-(x) = 0.5 \rightarrow \text{Cost} = -\log(0.5) = 0.69$
- $h_-(x) = 0.1 \rightarrow \text{Cost} = -\log(0.1) = 2.3$ Penalización alta

Si $y=0$:

- $h_-(x) = 0 \rightarrow \text{Cost} = -\log(1) = 0$ Sin penalización
- $h_-(x) = 0.5 \rightarrow \text{Cost} = -\log(0.5) = 0.69$
- $h_-(x) = 0.9 \rightarrow \text{Cost} = -\log(0.1) = 2.3$ Penalización alta

5.7.5 Algoritmo de Descenso de Gradiente

Actualización (¡idéntica en forma a regresión lineal!):

$$:= - \times (1/m) \times \sum [h_-(x) - y] \times x$$

Pero recuerda:

$$h_-(x) = 1/(1 + e^{(-x)}) \leftarrow \text{Diferente de regresión lineal}$$

7.6 Clasificación Multiclase

Estrategia: One-vs-All (uno contra todos)

Proceso:

Problema: Clasificar emails en 3 categorías

- Clase 1: Personal
- Clase 2: Trabajo
- Clase 3: Spam

Entrenamos 3 clasificadores:

Clasificador 1: ¿Es Personal? (sí vs no)

Clasificador 2: ¿Es Trabajo? (sí vs no)

Clasificador 3: ¿Es Spam? (sí vs no)

Para un nuevo email:

$h(x) = 0.2$ (20% probabilidad Personal)

$h(x) = 0.7$ (70% probabilidad Trabajo) ← ¡Máximo!

$h(x) = 0.1$ (10% probabilidad Spam)

Predicción final: Trabajo

5.8 Regresión Polinómica

Objetivo: Ajustar curvas (no solo líneas rectas).

Idea: Crear nuevas características elevando las originales a potencias.

Original:

$$h_-(x) = \quad + \quad x$$

Cuadrática:

$$h_-(x) = \quad + \quad x + \quad x^2$$

Cúbica:

$$h_-(x) = \quad + \quad x + \quad x^2 + \quad x^3$$

Ejemplo visual:

Precio de casa según tamaño

Lineal:

Cuadrática:

Cúbica:

>

>

>

Simple

Mejor ajuste

Puede sobreajustar

5.9 Overfitting (Sobreajuste)

5.9.1 Los Tres Escenarios

Ejemplo con regresión:

UNDERFITTING
(Subajuste)

GOOD FIT
(Buen ajuste)

OVERFITTING
(Sobreajuste)

$h(x) = + x$ $h(x) = + x + x^2$ $h(x) = + \dots + x$

Sesgo alto	Balance	Varianza alta
No captura el patrón	Captura el patrón	Captura el ruido también

Ejemplo con clasificación:

UNDERFITTING	GOOD FIT	OVERFITTING
--------------	----------	-------------

Línea recta muy simple	Curva suave apropiada	Frontera errática se ajusta al ruido
------------------------	-----------------------	--------------------------------------

5.9.2 Soluciones al Overfitting

Solución 1: Reducir número de características

Manualmente:

- Eliminar características poco relevantes

Automáticamente:

- Algoritmos de selección de características

Solución 2: Regularización **Concepto:** Penalizar parámetros θ muy grandes.

Nueva función de coste:

$$J() = [\text{coste original}] + \frac{\lambda}{2m} \times \sum \theta^2$$

Término de regularización

Donde:

λ (lambda) = parámetro de regularización

Efecto:

$\lambda = 0$:	Sin regularización → Posible overfitting
pequeño:	Poca regularización → Balance
grande:	Mucha regularización → Posible underfitting

Ejemplo:

Si λ es muy grande, forzamos todos los $\theta = 0$

Resultado: $h(x)$ (función constante) → Underfitting

Regresión lineal regularizada:

$$:= \underbrace{- \times [(1/m)\Sigma(h_{\theta}(x) - y)x]}_{\text{término original}} + \underbrace{(\lambda/2m)}_{\text{regularización}}$$

5.10 Flujo Completo de un Proyecto de ML

1. DEFINIR EL PROBLEMA
¿Regresión o Clasificación?
↓
2. RECOPILAR DATOS
Conjunto de entrenamiento (x, y)
↓
3. PREPROCESAR DATOS
 - Limpiar datos
 - Normalizar características
 - Dividir en entrenamiento/test
 ↓
4. ELEGIR MODELO
 - Regresión lineal
 - Regresión logística
 - Otro algoritmo
 ↓
5. ENTRENAR MODELO
 - Inicializar
 - Minimizar J() con descenso de gradiente
 ↓
6. EVALUAR MODELO
 - Probar en datos de test
 - Verificar overfitting/underfitting
 ↓
7. AJUSTAR Y MEJORAR
 - Cambiar
 - Añadir/quitar características
 - Aplicar regularización
 ↓
8. DESPLEGAR
Usar el modelo en producción